STORY 2

Classifier les champignons avec PySpark

Découverte de la librairie PySpark



Story

Dans ce brief vous allez découvrir la syntaxe de la librairie PySpark en classifiant si des champignons sont comestibles ou toxiques. Vous pourrez trouver plus d'informations à propos du DataSet dans les ressources.

1. Explorer vos données
2. Vous réaliserez au minimum un modèle (choix libre)
3. Evaluer vos modèles
4. Choisir le meilleur et le sauvegarder.

Note : Afin de faciliter la découverte de PySpark, ce projet est prévu pour un fonctionnement en local et donc le volume de données est faible.

Modalités pédagogiques

- Utiliser PySpark pour créer un modèle de classification le plus performant (comparer avec les autres).
- Et Transformer votre modèle en API
- Faire les 2 workshops

2 jours pour produire les livrables

Objectifs visés d'apprentissage

C1. Automatiser l'extraction de données depuis un service web, une page web (scraping*), un fichier de données, une base de données et un système big data* en programmant le script* adapté afin de pérenniser la collecte des données nécessaires au projet.

C2. Développer des requêtes de type SQL d'extraction des données depuis un système de gestion de base de données et un système big data en appliquant le langage de requête propre au système afin de préparer la collecte des données nécessaires au projet.

C5. Développer une API mettant à disposition le jeu de données en utilisant l'architecture REST afin de permettre l'exploitation du jeu de données par les autres composants du projet.

C6. Organiser et réaliser une veille technique et réglementaire en animant le travail collectif de sélection des sources, de collecte, de traitement et de partage des informations afin de formuler des recommandations pour le projet toujours en phase avec l'état de l'art.

Livrables

Un lien GitHub dans le portail NET YPAREO

Ressources

PySpark Tutorial For Beginners (Spark with Python) :

PySpark 3.5 Tutorial For Beginners with Examples - Spark By {Examples} (sparkbyexamples.com)

Pyspark ML tutorial for beginners :

Pyspark ML tutorial for beginners (kaggle.com)

ML Tuning: model selection and hyperparameter tuning :

ML Tuning - Spark 3.5.2 Documentation (apache.org)

Workshop 1 sans Docker :

Les données : Mushroom Classification :

Mushroom Classification (kaggle.com)

Pyspark MLlib | Classification using Pyspark ML :

Pyspark MLlib | Classification using Pyspark ML | Towards AI

Workshop 2 avec Docker :

Data Engineering End-to-End Project — Spark, Kafka, Airflow, Docker, Cassandra, Python :

Data Engineering End-to-End Project — Spark, Kafka, Airflow, Docker, Cassandra, Python | by Dogukan Ulu | Medium